Language Modeling

Luciano Barbosa

Centro de Informática
UFPE
Universidade Federal de Pernambuco

Definição

- Tarefa que prediz próximas palavras

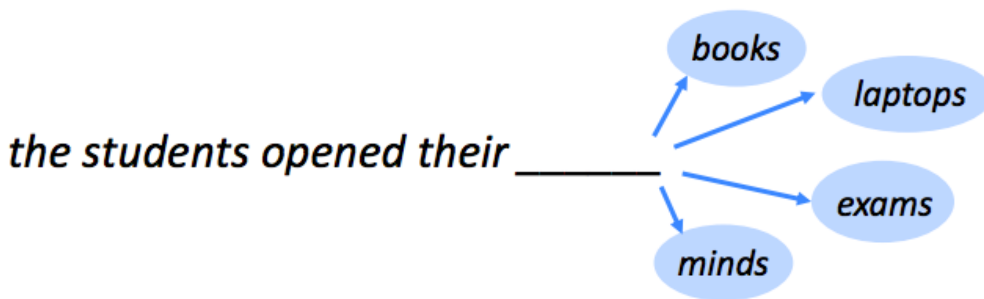

- Com ... ada uma sequência de palavras

- Computar a probabilidade de uma sequência de palavras

$$P(w_5 | w_1, w_2, w_3, w_4)$$

$$P(W) = P(w_1, w_2, w_3, w_4, w_5 \ldots w_n)$$

Onde São Usados

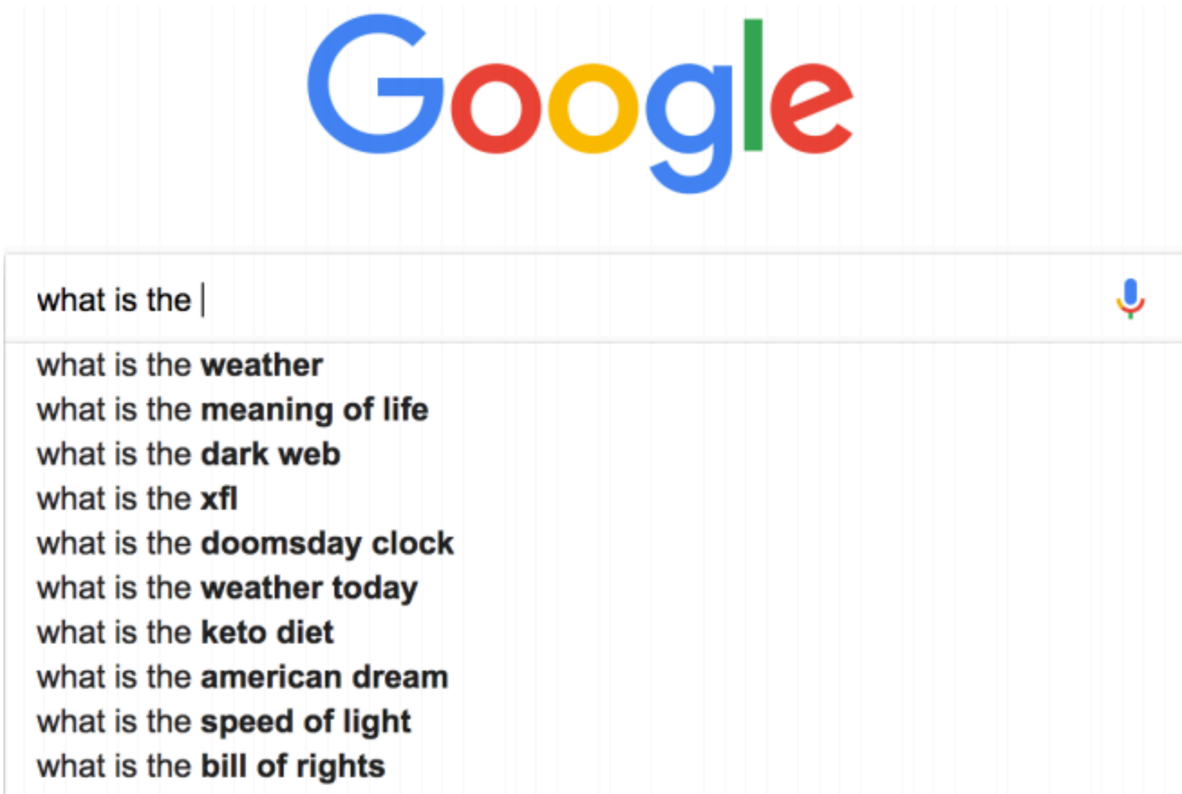

Onde São Usados

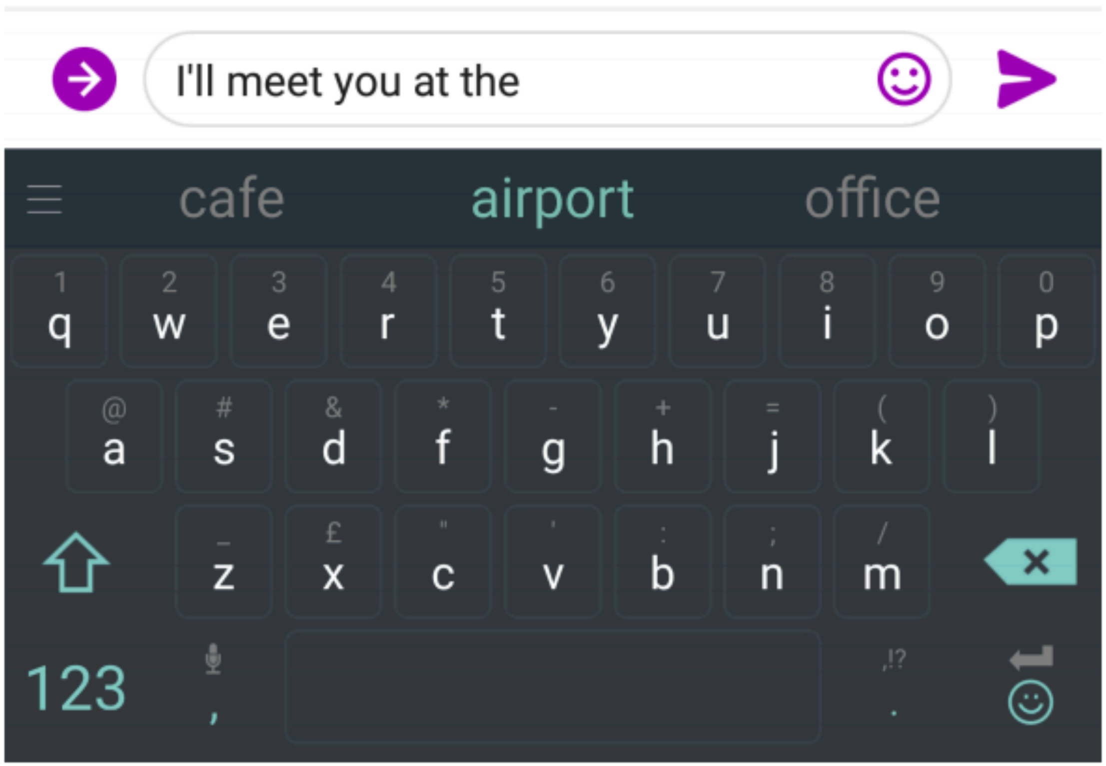

Onde São Usados

- Gerar texto ou estimar a probabilidade de um texto
- Compenente de várias tarefas de PLN
  - Corretor ortográfico
  - Reconhecedor de fala
  - Machine translation
  - Reconhecimento de escrita
  - Sumarização
  - Diálogo

Como Computar P(W)

- Ex: P(its, water, is, so, transparent, that)
- Utiliza chain rule de probabilidade

$$p(B|A) = P(A,B)/P(A) \longrightarrow P(A,B) = P(A)P(B|A)$$

$$P(A,B,C,D) = P(A)P(B|A)P(C|A,B)P(D|A,B,C)$$

$$P(x_1,x_2,x_3,\ldots,x_n) = P(x_1)P(x_2|x_1)P(x_3|x_1,x_2)\ldots P(x_n|x_1,\ldots,x_{n-1})$$

P("its water is so transparent") =

P(its) × P(water|its) × P(is|its water)

× P(so|its water is) × P(transparent|its water is so)

Como Calcular as Probabilidades

- Baseado na frequência em um corpus de dados

$$P(\text{the} \mid \text{its water is so transparent that}) = \frac{Count(\text{its water is so transparent that the})}{Count(\text{its water is so transparent that})}$$

- Problema: n-grams grandes são raros
- N-grams: sequência de n palavras consecutivas

Markov Assumption

- Usadas somente as palavras mais próximas

$$P(w_i \mid w_1 w_2 \ldots w_{i-1}) \approx P(w_i \mid w_{i-k} \ldots w_{i-1})$$

- Bigram: condicionado na palavra anterior

$$P(w_i \mid w_1 w_2 \ldots w_{i-1}) \approx P(w_i \mid w_{i-1})$$

- N-gram: trigrams, 4-grams, 5-grams
  - Linguagem tem dependências de longa distância

"The computer which I had just put into the machine room on the fifth floor crashed."

Estimando Probabilidades

- Maximum Likelihood Estimate

$$P(w_i \mid w_{i-1}) = \frac{c(w_{i-1}, w_i)}{c(w_{i-1})}$$

<s> I am Sam </s>

<s> Sam I am </s>

<s> I do not like green eggs and ham </s>

$$P(\texttt{I} \mid \texttt{<s>}) = \frac{2}{3} = .67 \qquad P(\texttt{Sam} \mid \texttt{<s>}) = \frac{1}{3} = .33 \qquad P(\texttt{am} \mid \texttt{I}) = \frac{2}{3} = .67$$

$$P(\texttt{</s>} \mid \texttt{Sam}) = \frac{1}{2} = 0.5 \qquad P(\texttt{Sam} \mid \texttt{am}) = \frac{1}{2} = .5 \qquad P(\texttt{do} \mid \texttt{I}) = \frac{1}{3} = .33$$

Exemplo: Berkeley Restaurant Project sentences

can you tell me about any good cantonese restaurants close by

mid priced thai food is what i'm looking for

tell me about chez panisse

can you give me a listing of the kinds of food that are available

i'm looking for a good place to eat breakfast

when is caffe venezia open during the day

Contagem dos Bigrams

- Total of 9222 sentenças

	i	want	to	eat	chinese	food	lunch	spend
i	5	827	0	9	0	0	0	2
want	2	0	608	1	6	6	5	1
to	2	0	4	686	2	0	6	211
eat	0	0	2	0	16	2	42	0
chinese	1	0	0	0	0	82	1	0
food	15	0	15	0	1	4	0	0
lunch	2	0	0	0	0	1	0	0
spend	1	0	1	0	0	0	0	0

Resultado

- Contagem dos Unigrams

i	want	to	eat	chinese	food	lunch	spend
2533	927	2417	746	158	1093	341	278

- Probabilidades

	i	want	to	eat	chinese	food	lunch	spend
i	0.002	0.33	0	0.0036	0	0	0	0.00079
want	0.0022	0	0.66	0.0011	0.0065	0.0065	0.0054	0.0011
to	0.00083	0	0.0017	0.28	0.00083	0	0.0025	0.087
eat	0	0	0.0027	0	0.021	0.0027	0.056	0
chinese	0.0063	0	0	0	0	0.52	0.0063	0
food	0.014	0	0.014	0	0.00092	0.0037	0	0
lunch	0.0059	0	0	0	0	0.0029	0	0
spend	0.0036	0	0.0036	0	0	0	0	0

Estimando a Probabilidade de uma Sentença

$$
\begin{aligned}
&P(\langle s\rangle \text{ I want english food } \langle /s\rangle) = \\
&P(\text{I}|\langle s\rangle) \\
&\quad \times P(\text{want}|\text{I}) \\
&\quad \times P(\text{english}|\text{want}) \\
&\quad \times P(\text{food}|\text{english}) \\
&\quad \times P(\langle /s\rangle|\text{food}) \\
&= .000031
\end{aligned}
$$

Na Prática

- Cálculo em log
  - Evitar overflow
  - Adicionar é mais rápido que multiplicar

$$\log(p_1 \times p_2 \times p_3 \times p_4) = \log p_1 + \log p_2 + \log p_3 + \log p_4$$

Problema com Esparsidade

- OOV: out of vocabulary

Training set:
... denied the allegations
... denied the reports
... denied the claims
... denied the request

P("offer" | denied the) = 0

- Test set
  ... denied the offer
  ... denied the loan

Smoothing

- Retira probabilidade dos n-grams no corpus

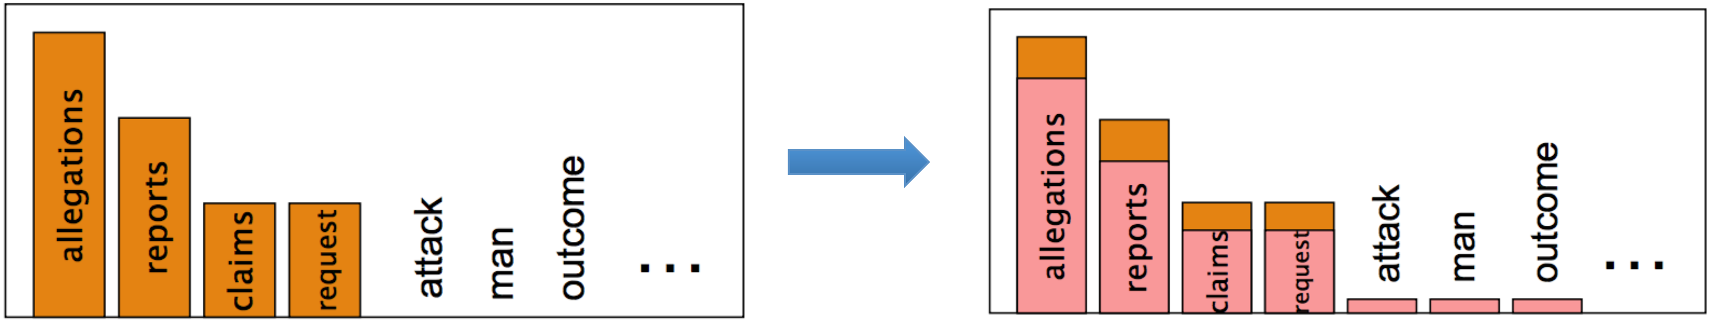

Laplace Smoothing

- Adiciona 1 a contagens

$$P_{Add-1}(w_i \mid w_{i-1}) = \frac{c(w_{i-1}, w_i) + 1}{c(w_{i-1}) + V}$$

Contagem dos Bigrams com Laplace

- Total of 9222 sentenças

	i	want	to	eat	chinese	food	lunch	spend
i	6	828	1	10	1	1	1	3
want	3	1	609	2	7	7	6	2
to	3	1	5	687	3	1	7	212
eat	1	1	3	1	17	3	43	1
chinese	2	1	1	1	1	83	2	1
food	16	1	16	1	2	5	1	1
lunch	3	1	1	1	1	2	1	1
spend	2	1	2	1	1	1	1	1

Contagem dos Bigrams com Laplace

$$P^*(w_n|w_{n-1}) = \frac{C(w_{n-1}w_n)+1}{C(w_{n-1})+V}$$

	i	want	to	eat	chinese	food	lunch	spend
i	0.0015	0.21	0.00025	0.0025	0.00025	0.00025	0.00025	0.00075
want	0.0013	0.00042	0.26	0.00084	0.0029	0.0029	0.0025	0.00084
to	0.00078	0.00026	0.0013	0.18	0.00078	0.00026	0.0018	0.055
eat	0.00046	0.00046	0.0014	0.00046	0.0078	0.0014	0.02	0.00046
chinese	0.0012	0.00062	0.00062	0.00062	0.00062	0.052	0.0012	0.00062
food	0.0063	0.00039	0.0063	0.00039	0.00079	0.002	0.00039	0.00039
lunch	0.0017	0.00056	0.00056	0.00056	0.00056	0.0011	0.00056	0.00056
spend	0.0012	0.00058	0.0012	0.00058	0.00058	0.00058	0.00058	0.00058

Add-one

- Não é usado para n-grams
- Usado em outros modelos de PLN
  - Classificação de texto

Backoff e Interpolação

- Usa menos contexto (menores n-grams)
- Backoff
  - Usar trigram se tiver dados suficientes
  - Senão, brigram ou então unigram
- Interpolação: combina unigram, bigram e trigram

Interpolação Linear

$$\begin{aligned}\hat{P}(w_n|w_{n-2}w_{n-1}) \;=\; & \lambda_1 P(w_n|w_{n-2}w_{n-1}) \\ & +\lambda_2 P(w_n|w_{n-1}) \\ & +\lambda_3 P(w_n)\end{aligned}$$

$$\sum_i \lambda_i = 1$$

- Usar um held-out set para encontrar lambdas

Gerando Sentenças

$\underbrace{\textit{today the}}_{\text{condition on this}}$ ________

get probability distribution

company	0.153
bank	0.153
price	0.077
italian	0.039
emirate	0.039
…	

sample

Gerando Sentenças

today the price ________

condition on this

get probability distribution

of	0.308	sample
for	0.050	
it	0.046	
to	0.046	
is	0.031	
…		

Gerando Sentenças

today the price of ________

condition on this

get probability distribution

the	0.072
18	0.043
oil	0.043
its	0.036
gold	0.018
…	

sample

Limitação: Contexto Limitado

~~as the proctor started the clock, the~~ *students opened their* ______

discard

condition on this

$$P(\boldsymbol{w}|\text{students opened their}) = \frac{\text{count}(\text{students opened their } \boldsymbol{w})}{\text{count}(\text{students opened their})}$$

"students opened their" occurred 1000 times

"students opened their books" occurred 400 times

- → P(books | students opened their) = 0.4

"students opened their exams" occurred 100 times

- → P(exams | students opened their) = 0.1

Limitação: Armazenamento dos Contadores

Storage: Need to store count for all *n*-grams you saw in the corpus.

$$P(\boldsymbol{w}|\text{students opened their}) = \frac{\boxed{\text{count}(\text{students opened their } \boldsymbol{w})}}{\text{count}(\text{students opened their})}$$

Neural Language Models: Janela Fixa

output distribution

$$\hat{\boldsymbol{y}} = \mathrm{softmax}(\boldsymbol{U}\boldsymbol{h} + \boldsymbol{b}_2) \in \mathbb{R}^{|V|}$$

hidden layer

$$\boldsymbol{h} = f(\boldsymbol{W}\boldsymbol{e} + \boldsymbol{b}_1)$$

concatenated word embeddings

$$\boldsymbol{e} = [\boldsymbol{e}^{(1)}; \boldsymbol{e}^{(2)}; \boldsymbol{e}^{(3)}; \boldsymbol{e}^{(4)}]$$

words / one-hot vectors

$$\boldsymbol{x}^{(1)}, \boldsymbol{x}^{(2)}, \boldsymbol{x}^{(3)}, \boldsymbol{x}^{(4)}$$

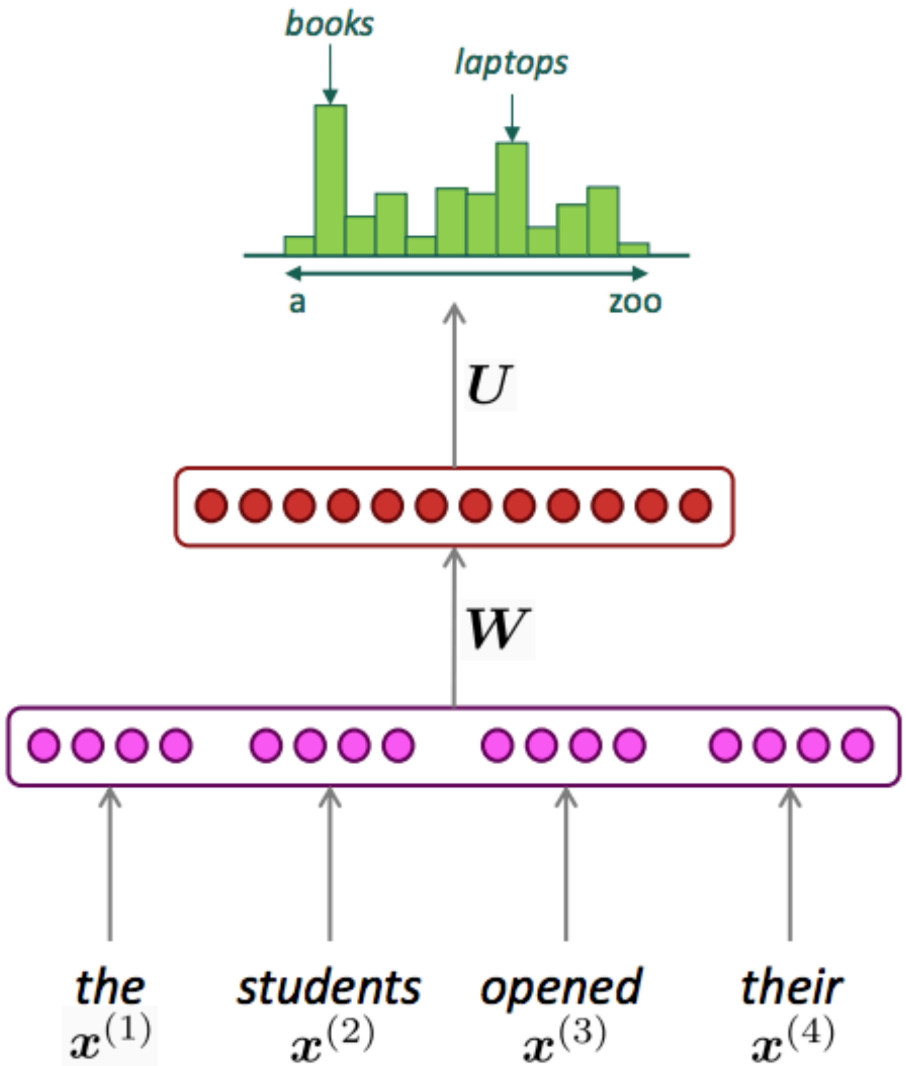

Neural Language Models: Janela Fixa

- Vantagens:
  - Não tem problema com esparsidade
  - Não precisa armazenar os contadores dos n-grams

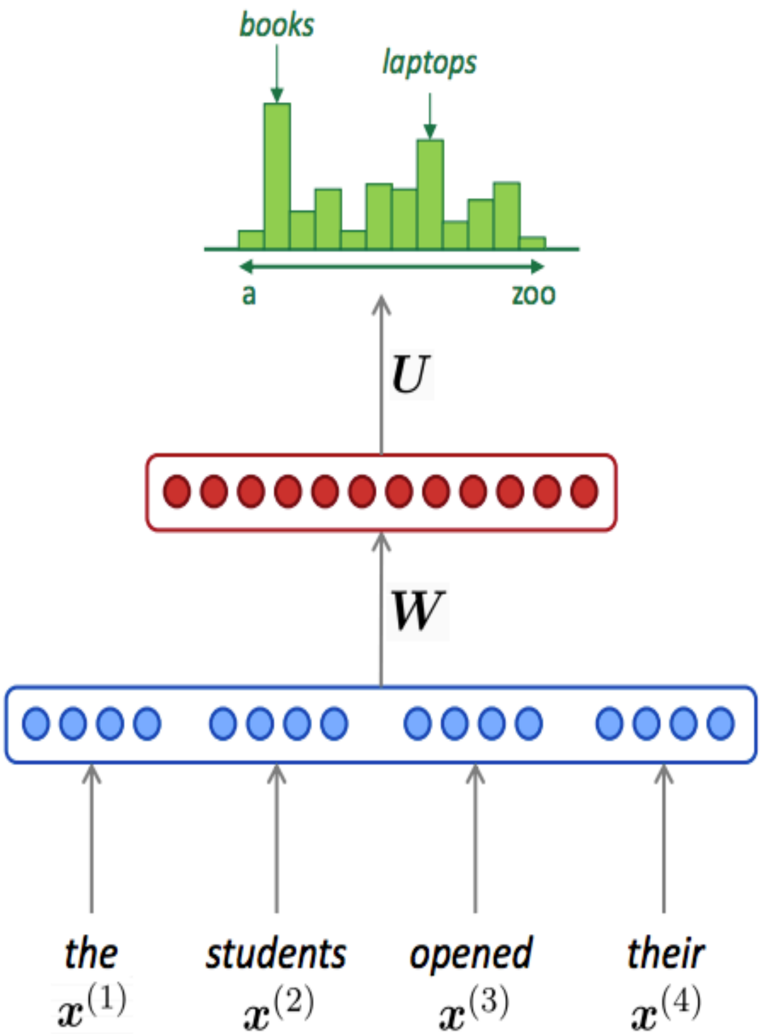

Neural Language Models: Janela Fixa

- Desvantagens:
  - Janela fixa pequena
  - Aumento da janela aumenta a complexidade (W)

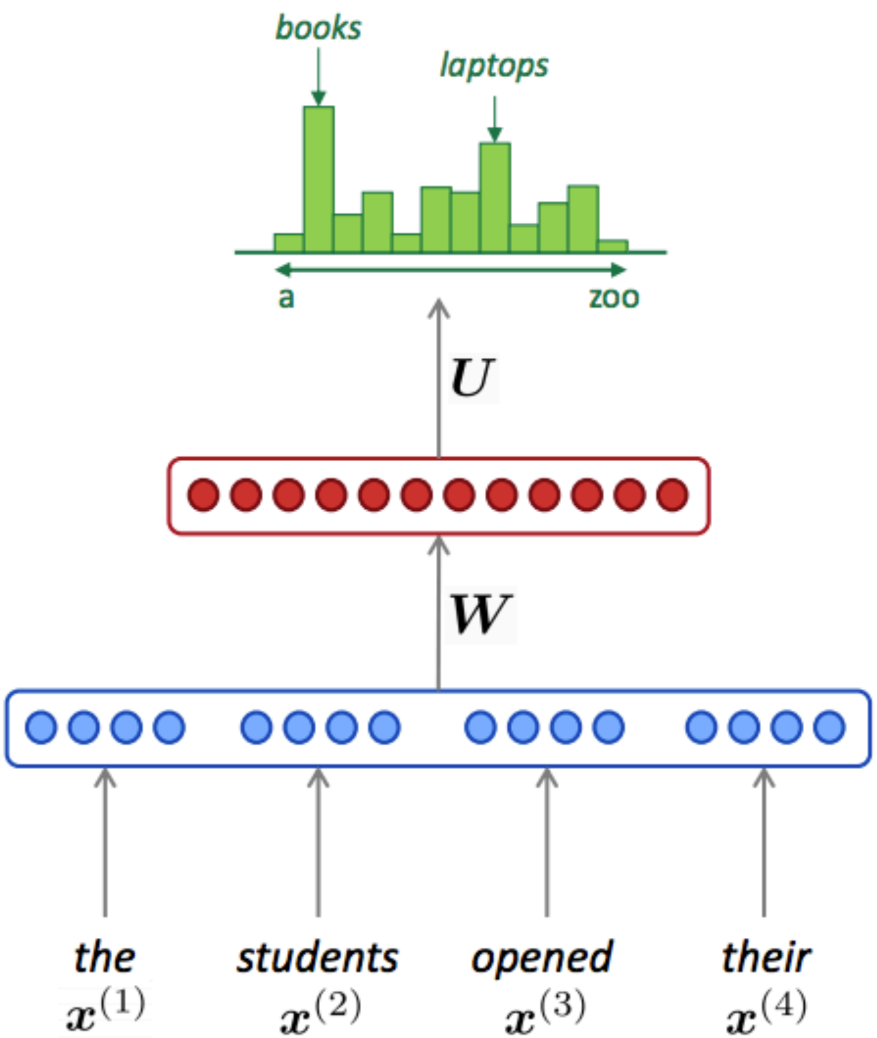

Recurrent Neural Networks (RNN)

output distribution

$\hat{\boldsymbol{y}}^{(t)} = \mathrm{softmax}\left(\boldsymbol{U}\boldsymbol{h}^{(t)} + \boldsymbol{b}_2\right) \in \mathbb{R}^{|V|}$

hidden states

$\boldsymbol{h}^{(t)} = \sigma\left(\boldsymbol{W}_h\boldsymbol{h}^{(t-1)} + \boldsymbol{W}_e\boldsymbol{e}^{(t)} + \boldsymbol{b}_1\right)$

$\boldsymbol{h}^{(0)}$ is the initial hidden state

word embeddings

$\boldsymbol{e}^{(t)} = \boldsymbol{E}\boldsymbol{x}^{(t)}$

words / one-hot vectors

$\boldsymbol{x}^{(t)} \in \mathbb{R}^{|V|}$

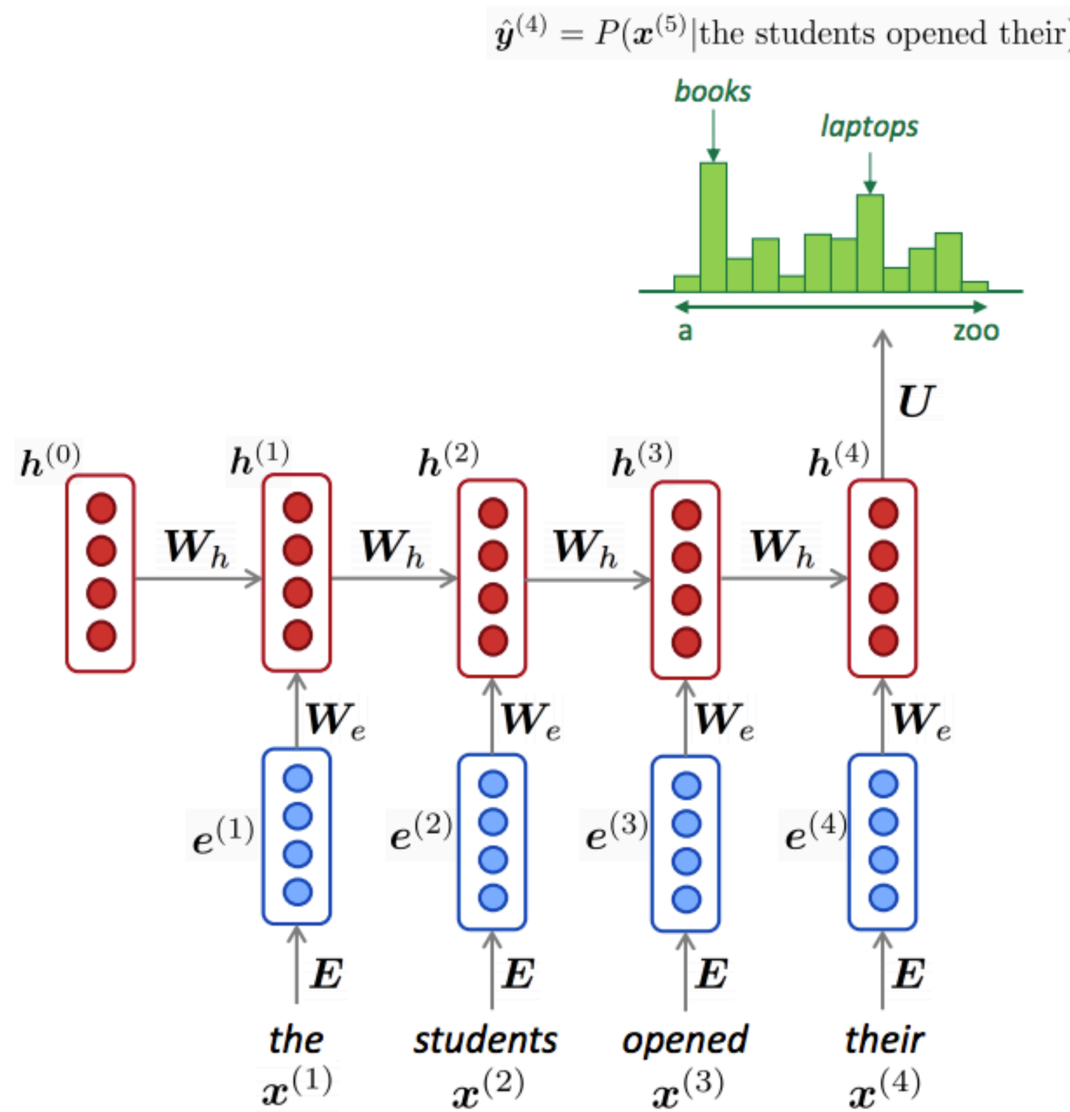

Recurrent Neural Networks (RNN)

- Vantagens
  - Pode processar sequência de qualquer tamanho
  - Modelo não aumenta com o tamanho da sequência
  - Usa informação anterior
  - Mesmos pesos utilizados em cada passo
- Desvantagens
  - Lenta
  - Na prática, tem dificuldade em guardar informação de palavras muito anteriores

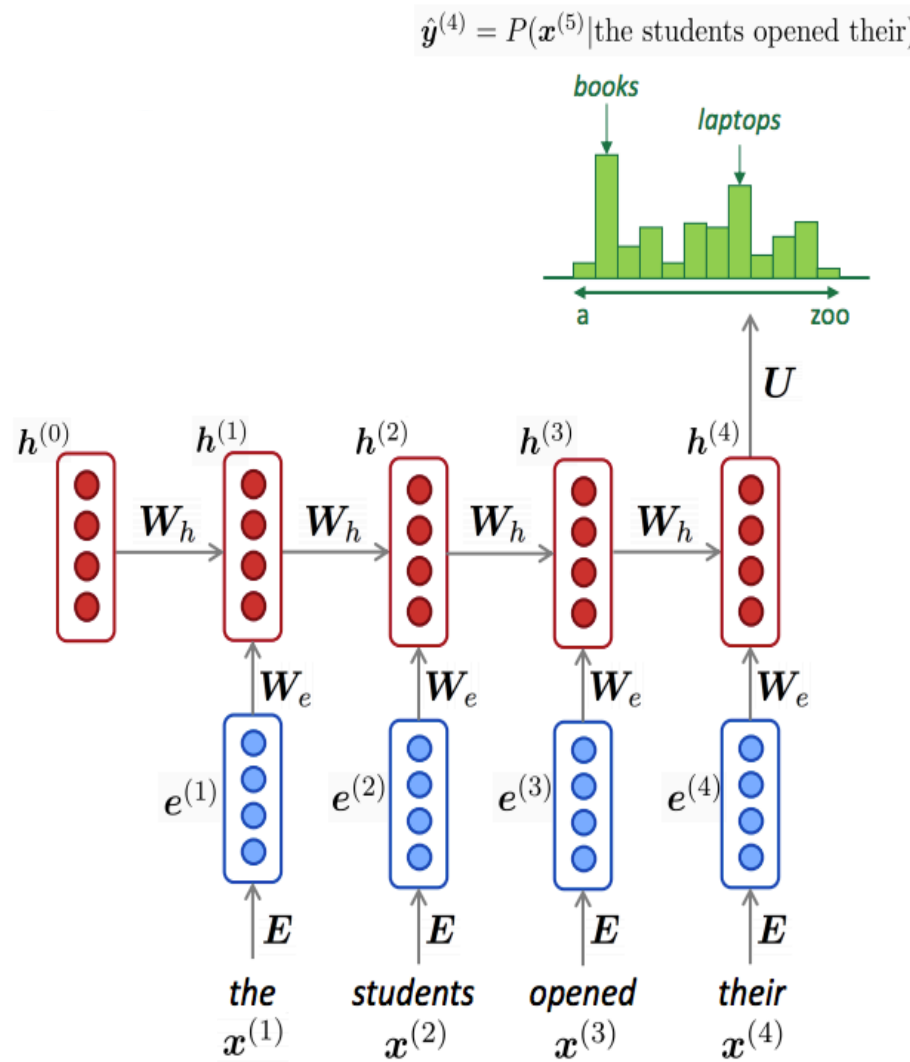

Geração de Texto

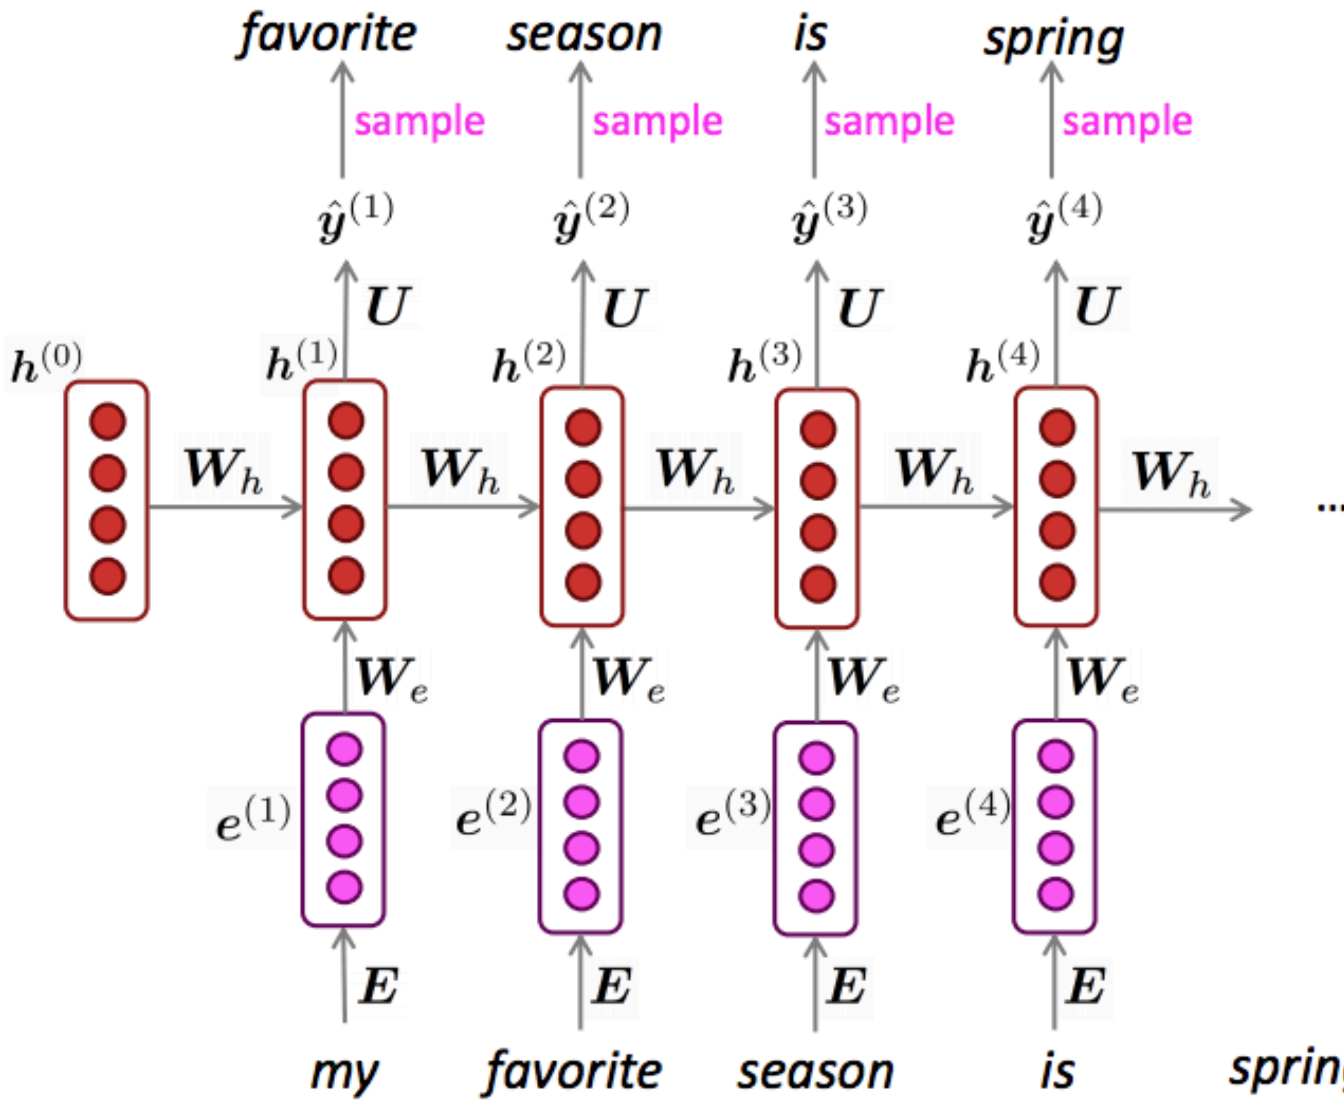

Exemplo de Texto Gerado com Discursos de Obama

The United States will step up to the cost of a new challenges of the American people that will share the fact that we created the problem. They were attacked and so that they have to say that all the task of the final days of war that I will not be able to get this done.

https://medium.com/@samim/obama-rnn-machine-generated-political-speeches-c8abd18a2ea0

Exemplo de Texto Gerado com Para Receitas

```
     Title: CHOCOLATE RANCH BARBECUE
Categories: Game, Casseroles, Cookies, Cookies
     Yield: 6 Servings

     2 tb Parmesan cheese -- chopped
     1 c  Coconut milk
     3    Eggs, beaten

Place each pasta over layers of lumps. Shape mixture into the moderate oven and simmer
until firm. Serve hot in bodied fresh, mustard, orange and cheese.

Combine the cheese and salt together the dough in a large skillet; add the ingredients
and stir in the chocolate and pepper.
```

https://gist.github.com/nylki/1efbaa36635956d35bcc

Avaliação de LMs: Extrínsica

- Colocar o LM em uma tarefa
  - Corretor ortográfico, reconhecedor de fala, MT
- Executar a tarefa e calcular a acurácia entre modelos
- Problema: pode ser custoso criar essas tarefas

Avaliação de LMs: Intrínsica

- Perplexity
- Funciona bem quando o conjunto de teste é “próximo” do de treinamento
- O modelo LM é que melhor prediz um sequência de teste

Perplexity

- Quanto menor, melhor o modelo

$$PP(W) = P(w_1 w_2 \ldots w_N)^{-\frac{1}{N}}$$

$$= \sqrt[N]{\frac{1}{P(w_1 w_2 \ldots w_N)}}$$

$$\mathrm{PP}(W) = \sqrt[N]{\prod_{i=1}^{N} \frac{1}{P(w_i | w_1 \ldots w_{i-1})}}$$

$$\mathrm{PP}(W) = \sqrt[N]{\prod_{i=1}^{N} \frac{1}{P(w_i | w_{i-1})}}$$

Comparação de Estratégias

n-gram model

Increasingly complex RNNs

Model	Perplexity
Interpolated Kneser-Ney 5-gram (Chelba et al., 2013)	67.6
RNN-1024 + MaxEnt 9-gram (Chelba et al., 2013)	51.3
RNN-2048 + BlackOut sampling (Ji et al., 2015)	68.3
Sparse Non-negative Matrix factorization (Shazeer et al., 2015)	52.9
LSTM-2048 (Jozefowicz et al., 2016)	43.7
2-layer LSTM-8192 (Jozefowicz et al., 2016)	30
Ours small (LSTM-2048)	43.9
Ours large (2-layer LSTM-2048)	39.8

Perplexity improves (lower is better)

Source: https://research.fb.com/building-an-efficient-neural-language-model-over-a-billion-words/